Déployez un modèle dans le cloud

**Entreprise:** Fruits!

Objectif: Prendre en photographie un fruit et obtenir des informations sur ce fruit => Computer Vision

Problématique: Architecture BigData pour passage à l'échelle

Mission: Chaine de traitement des données avec preprocessing et réduction de dimensionnalité







#### Vue d'ensemble


Dossiers: Images tailles « standardisées » + images tailles originales

Sous dossiers: Training 50% / Test 25 % / Validation 25 %

90380 Images

(67692 Train, 22688 Test)

131 Espèces Fruits Number of images per fruits (Training folder)






#### Méthode de création du DataSet & Exemples d'Images

Fruits sont filmés 360°


Images de fruits sont extraites avec un algorithme pour uniformiser le fond






#### PCA mise à l'échelle










#### Calcul distribué

Logique MapReduce (diviser) => Apache Hadoop (distribuer avec un cluster)

Apache Hadoop(SSD)/Apache Spark(RAM)

Architecture Master-workers





## **Pyspark**

Apache Spark (Java) => PySpark

Lazy evaluation (Transformations VS actions)

MLSpark



## **Pyspark**

Resilient Distributed Datasets (RDD)

**DataFrames** 

**UDF** 

Map

# Mais moins facile d'utilisation avec MLSpark

```
Preprocessing

|: df = spark.read.format("binaryFile").load(s3_object_path)

|: feature_extracted_df = df.select(feature_extract_UDF(df.content).alias("features"))

|: vector_df = feature_extracted_df.select(to_vector_UDF('features').alias('features'))
```



#### **Feature Extraction VGG16**

#### Deep Learning

Convolutional neural network (CNN)

Architecture VGG16 (implémentée de façon à être remplacée par une autre si nécessaire et si appartient à Keras)

Paramètres entrainables = 0

Dernière couche: Max pooling (possible d'intervertir avec d'autres poolings ou une flatten layer)

Dimensions de sortie : vecteur (1,512) pour une image

Model: "vgg16"

Layer (type)	Output Shape	Param #
input_1 (InputLayer)		
block1_conv1 (Conv2D)	(None, 224, 224, 64)	1792
block1_conv2 (Conv2D)	(None, 224, 224, 64)	36928
block1_pool (MaxPooling2D)	(None, 112, 112, 64)	0
olock2_conv1 (Conv2D)	(None, 112, 112, 128)	73856
block2_conv2 (Conv2D)	(None, 112, 112, 128)	147584
block2_pool (MaxPooling2D)	(None, 56, 56, 128)	0
olock3_conv1 (Conv2D)	(None, 56, 56, 256)	295168
olock3_conv2 (Conv2D)	(None, 56, 56, 256)	590080
block3_conv3 (Conv2D)	(None, 56, 56, 256)	590080
olock3_pool (MaxPooling2D)	(None, 28, 28, 256)	0
olock4_conv1 (Conv2D)	(None, 28, 28, 512)	1180160
olock4_conv2 (Conv2D)	(None, 28, 28, 512)	2359808
block4_conv3 (Conv2D)	(None, 28, 28, 512)	2359808
block4_pool (MaxPooling2D)	(None, 14, 14, 512)	0
block5_conv1 (Conv2D)	(None, 14, 14, 512)	2359808
block5_conv2 (Conv2D)	(None, 14, 14, 512)	2359808
block5_conv3 (Conv2D)	(None, 14, 14, 512)	2359808
block5_pool (MaxPooling2D)	(None, 7, 7, 512)	0
global_max_pooling2d (Globa lMaxPooling2D)	(None, 512)	0

Trainable params: 0

Non-trainable params: 14,714,688



#### Pipeline Mise en Place

SparkSession => DataFrames

Pyspark Read Binaries

Pillow => np.array

Tansorflow => VGG16 MaxPooling 512
Dimensions

PysparkML Pipeline StandardScaler + PCA

Pyspark coalesce puis export csv

#### **Preprocessing**

```
Entrée [ ]: df = spark.read.format("binaryFile").load(s3_object_path)

Entrée [ ]: feature_extracted_df = df.select(feature_extract_UDF(df.content).alias("features"))

Entrée [ ]: vector_df = feature_extracted_df.select(to_vector_UDF('features').alias('features'))
```

#### **Dimentionality Reduction**



## Amazon Web Services (Vue d'ensemble non exhaustive)



BOTO3




Amazon Elastic Compute Cloud (Amazon EC2)






**AWS CLI** 







## Prototype d'architecture mis en place en local




#### Prototype d'architecture mis en place transition vers AWS




#### Prototype d'architecture mis en place sur AWS



#### Monitoring






**CPUs** 

t2.xlarge (4vCPU)
Port 4040 Spark UI
Amélioration performance possible : Tensorflow sur GPU
(entre autres)

#### Architecture lambda (adaptée)



#### Gestion des coûts

#### Services AWS utiles:

**AWS Cost Explorer** 


Pour Monitorer

. Pour Mieux apprehender coûts plus difficiles à anticiper dans notre cas : Stockage, Transfert de données



Savings Plans
Les instances réservées
permettent de faire des
économies
Différents types de Stockages


#### Couts prévisibles minimaux :



## Pour aller plus loin dans le projet de fruits!











HTTPS

URLs Présignées

VPC

Amazon Relational Database Service (Amazon RDS)

Amazon DynamoDB

#### Conclusion

Mise à l'échelle => calcul distribué => PySpark

Images => Feature Extraction + Réduction de dimentionalité (DataFrame, VGG16, ML Pipeline)

Architecture AWS (S3 buckets, EC2) et coûts associés

Développements possibles du projet => (EMR, PySpark Streaming, lambda Architecture, ML pipeline avec un modèle, Base de données [SQL, noSQL], sécurité de l'architecture)

Merci pour votre attention!